Carlos García Sánchez

19 de octubre de 2022

- "Intel Xeon Phi Processor High Performance Programming: Knights Landing Edition", James Jeffers, James Reinders, Avinash Sodani
- Youtube https://www.youtube.com/watch?v= sELW6-3roAc&ab_channel=Danysoft



Outline

- 1 Introducción
- 2 OpenMP
- 3 Tareas a realizar por el alumno
- 4 Intel Performance Tools



Secuencial vs Paralelo

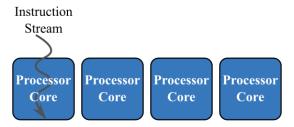
Aplicación secuencial en sistema con un único core





Secuencial vs Paralelo

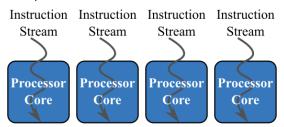
Aplicación secuencial en sistema con varios cores





Secuencial vs Paralelo

Aplicación paralela en sistema con varios cores





Modelos de memoria Sist. Paralelos

Memoria compartida vs Memoria Distribuida



Modelos de memoria compartida

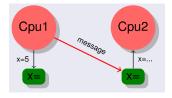
- Memoria es compartida por todos los procesadores: se permite el uso de hilos
- Existen mecanismos de comunicación y sincronización a través de la memoria compartida

$$\begin{array}{c|c}
Cpu1 & \xrightarrow{x=5} & Cpu2
\end{array}$$



Modelos de memoria distribuida

- Cada proceso tiene su propio espacio de direcciones de memoria
 - Ese espacio de memoria no es accesible por otros **procesos**
- La comunicación y sincronización se lleva a cabo explicitamente mediante mensajes





Modelos de memoria compartida vs distribuida

■ Hilos (OpenMP) vs procesos (MPI)







OpenMP

- OpenMP explota el paralelismo mediante hilos/threads
- Un hilo es entidad más pequeña de procesamiento
 - Más liviano que un proceso
- Habitualmente, un número de hilos se pueden mapear sobre una máquina multiprocesador/core

Paralelismo explícito

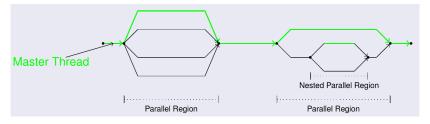
- OpenMP es un paradigma de programación explícito (no automático)
- Expresado mediante directivas
- Utiliza modelo fork-join



Modelo de ejecución

Modelo fork-join

- El hilo master crea un conjunto de hilos que acaban al finalizar la región paralela
- Los hilos pueden colaborar





- En esta práctica vamos a utilizar el compilador de Intel (ICC/ICX)
- Herramienta de Monitorización (ADVISOR y VTUNE)
- Están disponibles activando las variables de entorno

```
Terminal #1
user@lab:~ $ source /opt/intel/oneapi/setvars.sh
 : initializing oneAPI environment ...
  bash: BASH VERSION = 4.4.20(1)-release
   args: Using "$0" for setvars.sh arguments:
 : advisor -- latest
:: ccl -- latest
 : clck -- latest
:: compiler -- latest
:: dal -- latest
:: debugger -- latest
:: dev-utilities -- latest
 : dnnl -- latest
:: dpcpp-ct -- latest
 : dpl -- latest
:: inspector -- latest
:: intelpython -- latest
:: ipp -- latest
:: ippcp -- latest
:: ipp -- latest
 : itac -- latest
:: mkl -- latest
:: mpi -- latest
:: tbb -- latest
:: vpl -- latest
:: vtune -- latest
:: oneAPI environment initialized ::
```



- Recordamos que en su momento clonamos el repositorio de las prácticas con en comando git clone
- Ahora actualizaremos el contenido del repositorio con el comando git pull y los códigos estarán disponbles enla carpeta lab2

```
Terminal #1
user@lab:~ $ git pull
remote: Enumerating objects: 19, done.
remote: Counting objects: 100% (19/19), done.
remote: Compressing objects: 100% (12/12), done.
remote: Total 15 (delta 2), reused 15 (delta 2), pack-reused 0
Unpacking objects: 100% (15/15), done.
From https://github.com/garsanca/CAP
  9c5324c..ac5dea3 main
                               -> origin/main
Updating 9c5324c..ac5dea3
Fast-forward
README md
figures/parallel_processor_parallel_code.png | Bin 0 -> 46832 bytes
src/lab2/HelloWorld/hello.c
                                             1 22 ++
```



Hello World

■ Imprime el ID del hilo y el número de procesadores disponibles

```
hello.c
#include <stdio.h>
#include <omp.h>
int main(){
   // This code is executed by 1 thread
   printf("OpenMP with %d max threads\n", omp_get_max_threads () );
   printf("OpenMP with %d procs available\n", omp_get num procs () );
   #pragma omp parallel
   // This code is executed in parallel
   // by multiple threads
   printf("Hello World from thread %d of %d threads\n",
       omp get thread num(), omp get num threads());
```



```
Terminal #1
user@lab:~ $ icc -o hello.icc hello.c -qopenmp -qopt-report
user@lab:~ $ more hello.optrpt
Begin optimization report for: main()
   Report from: OpenMP optimizations [openmp]
OpenMP Construct at hello.c(12,2)
remark #16201: OpenMP DEFINED REGION WAS PARALLELIZED
```



Hello World

```
Terminal #1
user@lab:~ $ export OMP_NUM_THREADS=3
user@lab:~ $ ./hello.icc
OpenMP with 3 max threads
OpenMP with 4 procs available
Hello World from thread 0 of 3 threads
Hello World from thread 1 of 3 threads
Hello World from thread 2 of 3 threads
```



Trabajo Compartido

- El ejemplo determina la lista de números primos desde 1-número entrada
 - **i** es primo si no tiene divisores (2, i/2)
 - #define DEBUG visualiza la lista de primos

```
prime.c
   //#pragma omp parallel...
   for (i=2; i<n; i++)
      not_flag = 0;
       j=2;
       while(j<=i/2 && !not_flag)
          if(i%j==0) // not prime
              not_flag=1;
          j++;
       if (j>=i/2 && !not_flag)
          primes[++k] = i;
   }
```



- Iteraciones del bucle i potencialmente paralelas
 - Iteraciones independientes

A tener en cuenta

- Uso de variables: privadas, compartidas.... ect
- Variable ++k es el índice de la lista de números primos
 - Posible carrera: problema read&update&write
 - Solución: #omp critical
 - Lista desordenada: implementar un sort(primes)



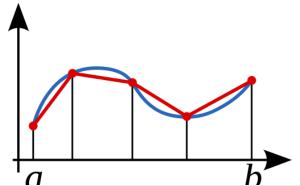
Trabajo Compartido

Clausula schedule

- STATIC
- STATIC, chunk
- DYNAMIC[, chunk]
- GUIDED[, chunk]
- AUTO



- Cálculo de la integral mediante el método del trapecio
 - Area del trapecio $S = \frac{1}{2}(f(a') + f(b')) * h$
 - Integral como suma de trapecios: $\int_a^b f(x) \partial x = \sum \frac{f(a') + f(b')}{2} h$





- Podemos destacar dos tipos tareas:
 - Cálculo de areas de cada trapecio individual
 - Acumulación de trapecios (integral) donde potencialmente pueden aparecer condiciones de carrera

```
trap.c
double Trap(double a, double b, int n, double h) {
   double integral, area;
   int k;
   integral = 0.0;
   for (k = 1; k \le n; k++) {
       area = h*(f(a+k*h)+f(a+(k-1)*h))/2.0:
      integral+=area;
   }
   return integral;
} /* Trap */
```

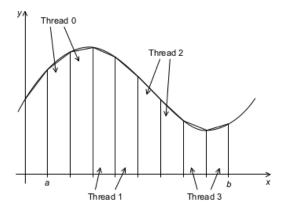


Condiciones de Carrera

Versiones

- atomic
- critical
- paralel for
 - reduction





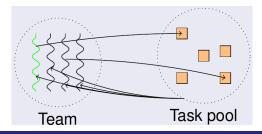


Condiciones de Carrera

```
trap_atomic.c
double Trap(double a, double b, int n, double h) {
   double integral, area, integral_thread;
   int k:
   int id, nths, n_per_thread, k_init_thread, k_end_thread;
   #pragma omp parallel private(...) firstprivate(...) shared(integral)
   id = ...
   nths = ...
   n_per_thread = n/nths;
   k init thread = ...
   k_end_thread = ...
   integral = 0.0:
   for (k = k_init_thread; k <= k_end_thread; k++) {
      area = h*(f(a+k*h)+f(a+(k-1)*h))/2.0;
      integral_thread+=area;
   #pragma omp critical
   {integral += integral_thread;}
   return integral;
```



Tareas



¿Que es un tarea en OpenMP?

- Tareas = unidades de trabajo (ejecución puede diferirse)
- Las tareas se componen de:
 - código para ejecutar y datos
- Hilos pueden **cooperar** para ejecutarlas



Tareas

Sucesión de Fibonacci

Fibonacci

$$f_0 = 0$$

$$f_1 = 1$$

$$f_n = f_{n-1} + f_{n-2}$$
(1)



Tareas OMP

fibo.c

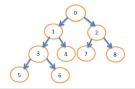
```
long comp_fib_numbers(int n)
   long fnm1, fnm2, fn;
   fnm1 = comp_fib_numbers(n-1);
   fnm2 = comp_fib_numbers(n-2);
   fn = fnm1 + fnm2;
   return(fn);
int main(int argc, char* argv[]) {
   fibo = comp_fib_numbers(n);
   . . .
  /* main */
```



```
fibo_task.c
long comp_fib_numbers(int n)
   long fnm1, fnm2, fn;
   if ( n == 0 || n == 1 ) return(1):
   if ( n<20 ) return(comp_fib_numbers(n-1) +comp_fib_numbers(n-2));</pre>
   #pragma omp task...
   {fnm1 = comp_fib_numbers(n-1);}
   #pragma omp task...
   {fnm2 = comp_fib_numbers(n-2);}
   #pragma omp...
   fn = fnm1 + fnm2:
   return(fn):
int main(int argc, char* argv[]) {
#pragma omp parallel
   #pragma omp single
   fibo = comp_fib_numbers(n);
} /* main */
```



```
fibo_task.c
long comp_fib_numbers(int n)
   long fnm1, fnm2, fn;
   if ( n == 0 || n == 1 ) return(1):
   if ( n<20 ) return(comp_fib_numbers(n-1) +comp_fib_numbers(n-2));</pre>
   #pragma omp task...
   {fnm1 = comp_fib_numbers(n-1);}
   #pragma omp task...
   {fnm2 = comp_fib_numbers(n-2);}
   #pragma omp...
   fn = fnm1 + fnm2:
   return(fn):
```





- Empleo de la herramienta de perfilado Intel-VTune¹
- \blacksquare $C_{NM} = A_{NK} * B_{KM}$
 - Sin ningún paralelismo
 - Tamaño definido con #define NUM 1024 en multiply.h
- 5 versiones

multiply0.c

```
for(i=0; i<msize; i++) {</pre>
    for(j=0; j<msize; j++) {</pre>
        for(k=0; k<msize; k++) {</pre>
            c[i][j] = c[i][j] + a[i][k] * b[k][j];
```



- Versión 1: OpenMP
 - #define MULTIPLY multiply1 en multiply.h

multiply1.c

```
// Basic parallel implementation
#pragma omp parallel for
for(i=0; i<msize; i++) {</pre>
   for(j=0; j<msize; j++) {</pre>
       for(k=0; k<msize; k++) {</pre>
           c[i][j] = c[i][j] + a[i][k] * b[k][j];
```



- Versión 2: OpenMP multi-bucle
 - #define MULTIPLY multiply2 en multiply.h

multiply2.c

```
#pragma omp parallel for collapse (2)
for(i=0; i<msize; i++) {</pre>
   for(k=0; k<msize; k++) {</pre>
       for(j=0; j<msize; j++) {</pre>
           c[i][j] = c[i][j] + a[i][k] * b[k][j];
```



- Versión 3: OpenMP multi-bucle y vectorización
 - #define MULTIPLY multiply3 en multiply.h

multiply3.c

```
#pragma omp parallel for collapse (2)
for(i=0; i<msize; i++) {</pre>
   for(k=0; k<msize; k++) {</pre>
       #pragma ivdep
       for(j=0; j<msize; j++) {</pre>
           c[i][j] = c[i][j] + a[i][k] * b[k][j];
```



- Versión 4: OpenMP multi-bucle, vectorización y desenrrollado
 - #define MULTIPLY multiply4 en multiply.h

multiply4.c

```
#pragma omp parallel for collapse (2)
for(i=0; i<msize; i++) {</pre>
   for(k=0; k<msize; k++) {</pre>
       #pragma unroll(8)
       #pragma ivdep
       for(j=0; j<msize; j++) {</pre>
           c[i][j] = c[i][j] + a[i][k] * b[k][j];
```



- Versión 5: uso de librerías
 - BLAS (Basic Linear Algebra Subroutine)
 - Operación GEMM:
 - \blacksquare C = α op (A) op (B) + β C
 - \blacksquare α y β son escalares
 - \blacksquare $A_{m \times k}$, $B_{k \times n}$ y $C_{n \times n}$ en (row-major)
 - #define MULTIPLY multiply5 en multiply.h

multiply5.c

```
double alpha = 1.0, beta = 0.;
cblas_dgemm(CblasRowMajor,CblasNoTrans,CblasNoTrans,
   NUM, NUM, NUM, alpha,
   (const double *)b,NUM,(const double *)a,NUM,beta,
   (double*)c.NUM):
```



Ecuación del calor

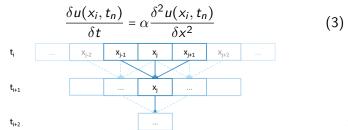
 La ecuación del calor (ec. difusión) es un problema comúnmente utilizado en los tutoriales de computación paralela

$$\frac{\delta u}{\delta t} = \alpha \frac{\delta^2 u}{\delta x^2} \tag{2}$$

- donde u(x,t) es la función a resolver dependiente de las coordenadas x y del tiempo t, α es el coeficiente de difusión
 - Para resolverla matemáticamente se procede a discretizar: la función se "expresa en un espacio acotado" mediante un mallado (grid) donde se aproxima $u(x_i, t_n)$ para cada punto el mallado



- La ecuación del calor (ec. difusión)
 - donde u(x,t) es la función a resolver
 - Para resolverla matemáticamente se procede a discretizar: la función se "expresa en un espacio acotado" mediante un mallado (grid) donde se aproxima $u(x_i, t_n)$ para cada punto el mallado





- La ecuación del calor (ec. difusión)
 - El siguiente paso es reemplazar la derivadas parciales por aproximaciones: diferencias finitas
 - La ec. calor en 1D

$$\frac{u_i^{n+1} - u_i^n}{\Delta t} = \alpha \frac{u_{i+1}^n - 2u_i^n + u_i^n}{\Delta x^2}$$
 (4)



- **Resumiendo**: la ecuación del calor es un problema comúnmente utilizado en los tutoriales de computación paralela
 - Consiste en la resolución de un sistema de ecuaciones aplicando el concepto de discretización
 - Los métodos de discretización más comunes son de primer grado de Euler
 - Utilizado en computación paralela por el número elevado de celdas que hay que "resolver" simultáneamente
 - Código extraido del Advanced Computing in Europe (PRACE)



 Resumiendo: la ecuación del calor-2D se resuelve discretizando cada punto con stencil de 5

$$c_t = c_{t-1} + \alpha \, \Delta t \left(\frac{l_{t-1} - 2c_{t-1} + r_{t-1}}{\Delta x^2} + \frac{d_{t-1} - 2c_{t-1} + u_{t-1}}{\Delta y^2} \right)$$



```
step_heat2D.c
```

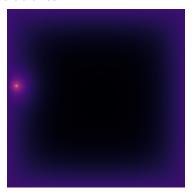
```
for (unsigned int v = 1; v < N-1; ++v) {
     for (unsigned int x = 1; x < N-1; ++x) {
        next[y*N+x] = current[y*N+x] + a * dt *
            ((current[v*N+x+1] - 2.0*current[v*N+x] + current[v*N+x
                -11)/dx2 +
             (current[(y+1)*N+x] - 2.0*current[y*N+x] + current[(y-1)*
                 N+x])/dy2);
```



- Inicializa con un valor rand las coordenadas de la fuente de calor: source_x, source_y
- Inicializa las condiciones de contorno
- Ejecución del bucle principal (it < MAX_ITERATIONS) && (t_diff > MIN_DELTA)
- Salida en fichero .png que muestra el calor en una placa 2D



■ Tras 20000 iteraciones





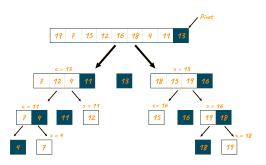
- Tareas a considerar:
 - Paralelizar el código **heat2d** con el paradigma OpenMP
 - Presta especial atención a la función step y diff
 - 3 Se recomienda utilizar la herramienta Intel vTune para encontrar los cuellos de botella y evaluar la escalabilidad de la paralelización OpenMP
 - 4 No olvides que puedes combinar paralelismo del tipo SIMD con paralelismo multi-hilos en los cores



Quicksort

- Algoritmo de ordenación basado en el concepto divide y vencerás
 - Elegir un elemento al que llamaremos pivote.
 - 2 Mover los demás elementos de la lista a cada lado del pivote
 - La lista inicial está separada en dos sublistas: con elementos menores y mayores al pivote
 - 3 Repetir el proceso de forma recursiva para cada sublista







Quicksort

- Tareas a considerar
 - Paralelizar el código con el paradigma OpenMP
 - El proceso recursivo tiene bastante similitudes con el cálculo de la sucesión de Fibonacci
 - Paralelización de tareas recomendable
 - 3 La variable debug=1 muestra por pantalla la lista ordenada



 Implementación de dinámica de fluidos como resolutor de ecuaciones para motores de juegos ²

Ecuaciones

■ Donde u corresponde a la velocidad y ρ al movimiento de la densidad repecto a la velocidad

https://www.youtube.com/watch?v=UM3VFnHBiOU

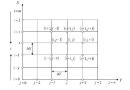


²Real-Time Fluid Dynamics for Games.

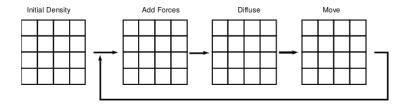
- Matemáticamente, el estado de un fluido en un instante de tiempo determinado se modela como un vector de velocidad: una función que asigna un vector de velocidad a cada punto del espacio
 - Ei: aire de radiador en una habitación, ciculará ascendentemente debido al aumento de calor
- El campo velocidad no es visualmente interesante hasta que se produce movimiento de objetos: como particulas de humo, polvo o las hojas



- El modelo se basa en el fluido que recorre una caja, por lo que se modelará como un espacio mediante diferencias finitas
 - u[size], v[size], u prev[size], v prev[size] representan las velocidades en una malla de tamaño size=(N+2)*(N+2)
 - dens[size], dens_prev[size] corresponde a la densidad del fluido
 - Acceso a las cordenadas se realiza con macro #define IX(i,j) ((i)+(N+2)*j)









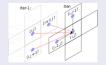
- Exiten dos ejecutables: demo y headless
 - **demo** es simulación gráfica (botón derecho del ratón añade densidad, izquierdo velocidad al fluido, v muestra velocidades y c inicializa simulación)
 - headless realiza 2048 iteraciones



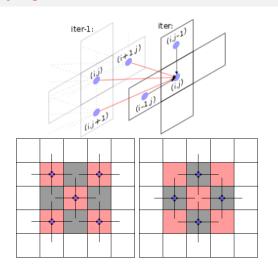


Optimizaciones

- Vectorización (recordad bucles independientes, accesos alineados, accesos consecutivos...)
- Paralelización: conveniente en bucles externos
- Función lin solve del fichero solver.c resuelve las ecuaciones aplicando el método numérico Gauss-Seidel (más complicado su paralelización), conviene resolverlo aplicando el método Jacobi (paralelización evidente) o en su defecto un red-black



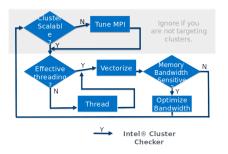






Herramientas de profiler

■ El proceso de paralelización se puede considerar un proceso iterativo





Intel APS-Application Performance Snapshot

- Vista rápida de algunos aspectos importantes en las aplicaciones de cómputo intensivo
 - Uso de MPI o OpenMP
 - Utilización de CPU
 - Acceso de memoria eficientes
 - Vectorización
 - E/S
 - Huella de la memoria



Intel APS-Application Performance Snapshot

- Fácil y rápido (vista rápida)
 - Haz un test en lo que tardas en preparer un café
 - Toda la información de un vistazo
- MPI + OpenMP + Memory + Floating Point
 - Soporta implementaciones MPI comunes
 - Intel® MPI, MPICH, OpenMPI y Cray MPI
- Novedades de version 2020
 - Diagnostico de comunicaciones
 - Tiempos en altos anchos de banda, no solamente édia





Free download.

intel.com/performance-snapshot



Intel APS-Application Performance Snapshot

- Para ejecutar:
 - aps my_app app_parameters
 - Genera report HTML





Intel VTune

- Intel® VTune™ Profiler
- Como mejorar el rendimiento con varios análisis
 - Hotspots
 - Threading Efficiency
 - Microarchitecture
 - Memory Access



Intel VTune

Variables de entorno

```
Terminal #1
user@lab:~ $ export INTEL STUDIO PATH=/usr/local/intel parallel studio xe cluster/
user@lab:~ $ source $INTEL_STUDIO_PATH/vtune_amplifier/amplxe-vars.sh
```

- La Herramienta Intel Vtune Amplier nos permite realizar un perfilado de la aplicación paralela para detectar posibles mejoras
 - Lanzamiento herramienta gráfica amplxe-gui, más moderno vtune-gui
 - Lanzamiento por línea de comandos amplxe-cl,más moderno vtune-collect





- 1 Proyecto actual con el análisis de configuración (New Project)
- Proyectos recientes
- Resultados recientes
- Recursos y documentación online
- 5 Artículos de y últimas noticias



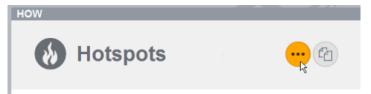
Intel VTune: Opciones de análisis

- Hotspots
 - Utilización de CPU
- Memory Consumption:
 - Consumo de memoria (malloc-free) en cada rutina
- Microarchitecure Exploration:
 - Analiza cuellos de botella que afectan al rendimiento
 - Contadores HW
- Memory Access
 - Identifica los accesos a jerarquía memoria (NUMA, DRAM, L2...)



Intel VTune: Análisis

- Más info en Intel-VTune³ y vídeo ⁴
- A la hora de crear el proyecto con New Project seleccionar Local Host para analizar en el equipo local
 - Introducir el ejecutable (path) y primer análisis Hotspots



³https://software.intel.com/en-us/vtune 4https://software.intel.com/en-us/videos/





- Hotspots dirigido a la optimización de software y conocer dónde pasa tiempo la aplicación: analizar la eficiencia
- Incluye los análisis:
 - Hotspots para identificar las funciones más costosas y muestra la actividad de cada hilo
 - Memory consuption para analizar el consumo de memoria: caches v RAM



Intel VTune: Parallelism Analysis

- Tipos de análisis para aplicaciones sensibles en cómputo: análisis general del rendimiento
- Incluye los análisis:
 - Threading: muestra balanceo de trabajo entre hilos y puntos de sincronización
 - Compute-intensive Application: caracterización rendimiento de HPC (punto flotante y la eficiencia de la memoria)



Intel VTune: multiply0

■ Sin paralelismo de ningun tipo

```
9 3+ ▶ ± 0 □ □ Welcome × #000hs x
                        Motspots Hotspots by CPU Utilization . (*)
r002hs
                                                                                                                                 Explore Additional Insights
Parallelism ::: 12.5% 8
Use © Threading to explore more

    Top Hotspots

                              This section lists the most active functions in your application. Optimizing these hotspot functions
                              multiplyO matrix.gcc
                              init_arr matrix.gcc 0.050s
                              init, or matrix got
                                                      0.0106

    Effective CPU Utilization Histogram

                              This histogram displays a percentage of the wall time the specific number of CPUs were running simultaneously. Spin and Over utilization value.
```



Intel VTune: multiply1

■ Más eficiencia paralela (OpenMP), pero gran demanda de memoria

```
P 5+ ▶ d. G □ □ Welcome × Compare...× mul v1 ×
Hotspots Hotspots by CPU Utilization . (2) 01
                                                                                                             INTELNTUNE AMPLIFIER 2019
     This section lists the most active functions in your application. Optimizing these hotspet functions
                                  libiomp6.so 0.388s
                                  liblomp5.so
                                                0.021s

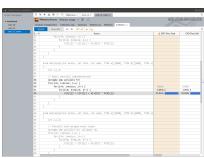
    Effective CPU Utilization Histogram 

     This histogram displays a percentage of the svall time the specific number of CPUs were running simultaneously. Spin and Overhead time adds to the Idle CPU
```



Intel VTune: multiply1

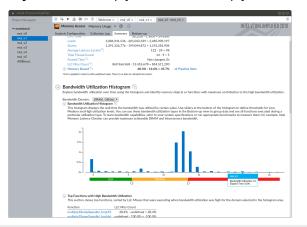






Intel VTune: multiply2 vs multiply3

■ **Memory Bound** multiply2: 60 % vs multiply3: 15 %



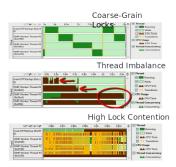


- Permite explorar
 - Wait Time: esperas prologandas por regiones de sincronización
 - Spin y Overhead Time: esperas y sobrecoste asociado al manejo de las regiones paralelas
 - Thread count: tiempo espera debido a sobresubscripción, espera a que los recursos compartidos esten disponibles cuando se ejecutan más hilos lógicos que cores físicos



- Problemas asociados al paralelismo
 - Asegurarse que se ejecutan todos los hilos disponibles
 - Problemas comunes a la concurrencia pueden diagnosticarse
 - Análisis para detectar la contención en operaciones tipo Locks/Waits





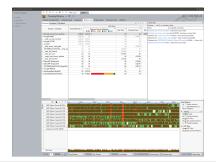


- Demo:
 - Paralelización bucle for
 - schedules: static, dynamic, guided
- Ej: Nbody-coulomb: static





- Demo:
 - Paralelización bucle for
 - schedules: static, dynamic, guided
- Ej: Nbody-coulomb: dynamic





- Demo:
 - Paralelización bucle for
 - schedules: static, dynamic, guided
- Ej: Nbody-coulomb: guided



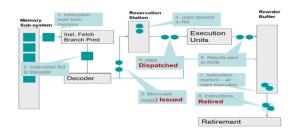


- Microarchitecture analysis Group introduce un tipo de análisis que ayuda a estimar los motivos de las ineficiencias en los procesadores modernos
 - Microarchitecture Exploration ayuda a identificar los problemas más communes que afectan al rendimiento de la aplicación. Se puede considerer este análisis como punto de partida al analísis a nivel hw
 - Memory Access mide una serie de métricas para identificar accesos a los diferentes niveles de la jerarquía de memoria (como por ejemplo en arquitecturas NUMA)



- Una vez completado el análisis Hotspots para conocer ineficiencias en tu código...
 - Se recomienda efectuar el análisis Microarchitecture
 Exploration analysis para comprender como las ineficiencias se manifiestan en el uso del pipeline del core
 - VTune Profiler recolecta una lista complete de eventos hw
 - Calcula unas métricas predefinidas = identifica a nivel hw problemas asociados a ineficiencias



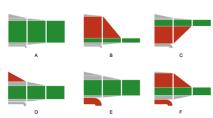




- Backend bound
- Uops posibles que no se puede lanzar al Fetch+Dec
- Retiring
- Uops completadas (1uop/cycle)
- Bad speculation
- Uops especuladas de forma incorrecta y no "retiradas"
- Backend bound
- Uops completadas, pero no 1 por ciclo (fallos cache)



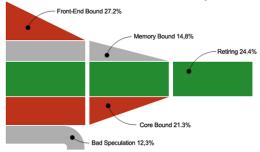
- A: sin problemas reseñables
- B: Memory bound
- C: Core bound
- D: Front End bound
- E: fallos en la especulación (por ejemplo branch misprediction)
- F: combinación de problemas relacionados con Memoria y mala Especulación





■ Ejemplo 1

■ Pipe presenta problemas significativos en Front-End Bound y Core Bound issues limitando la eficiencia global al 24.4 %





- Ejemplo 2
 - Buena Eficiencia con algún problema en el Front-End (instrucciones independientes)

