Práctica 4. Paralelización heterogénea con GPUs

Computación de Altas Prestaciones

Carlos García Sánchez

23 de noviembre de 2022

- "Computer Architecture: A Quantitative Approach", J.L. Hennessy, D.A. Patterson, Morgan Kaufmann 2011
- "Data Parallel C++: Mastering DPC++ for Programming of Heterogeneous Systems using C++ and SYCL", James Reinders

Outline

Objetivos

- Familiarizarse con la programación por medio de directivas con OpenMP
- Evaluar las mejoras/speedup

OpenMP

- Soportado en la Intel® oneAPI HPC Toolkit
- Uso del compilador ICX con soporte OpenMP offloading
  - Conocer las características de la GPU para poder compilar adecuadamente
  - Activación de OpenMP 4.5 con el flag `-fiopenmp` que a su vez tiene soporte **offloading** con el flag `-fopenmp-targets=spir64`
  - JIT compilation

Terminal #1

```
user@system:~$ icx -fiopenmp -fopenmp-targets=spir64 source.c
user@system:~$ ifx -fiopenmp -fopenmp-targets=spir64 source.f90
```

Compiladores de Intel C++

- Compatibles los binario y linkables https://www.intel.com/content/www/us/en/developer/articles/tool/oneapi-standalone-components.html

Compilador	target	OpenMP	OpenMP-offload	Toolkit
Intel C++ Compiler ILO **icc/icpc/icl**	CPU	SI	No	HPC
Intel® oneAPI DPC++ Compiler, **dpcpp**	CPU, GPU, FPGA	SI	SI	Base
Intel® oneAPI C++ Compiler, **icx/icpx**	CPU, GPU	SI	SI	Base

Ejemplo HelloWorld

- El primer ejemplo *simple.cpp* en la carpeta HelloWorld inicializa en el host un array `data`
- Y lo duplica en el device (construcción **target**)
  - Trasiego de datos con clausula **map**
  - ... recordar direccionalidad *from*, *to*, *fromto*

simple.c

```
...
  // Initialization
  for (int i = 0; i < N; i++) data[i] = i;

  // Add the target directive here, including the map clause.
#pragma omp target map(from : is_cpu) map(tofrom : data [0:N])
  {
    is_cpu = omp_is_initial_device();
#pragma omp parallel for
    for (int i = 0; i < N; i++) {
      data[i] *= 2;
    }
  }
...
```

Ejemplo HelloWorld

- Compilación con flags `-fiopenmp -fopenmp-targets=spir64`
- Para ejecutarlo simplemente se invoca el ejecutable de forma ordinaria
  - ¿Cómo saber si se ejecuta realmente en dispositivo?

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 simple.cpp -o simple
user@system:~$  ./simple
Running on GPU
0
2
4
6
8
10
12
14
16
18
20
22
24
26
28
30
```

Flujo compilación/ejecución

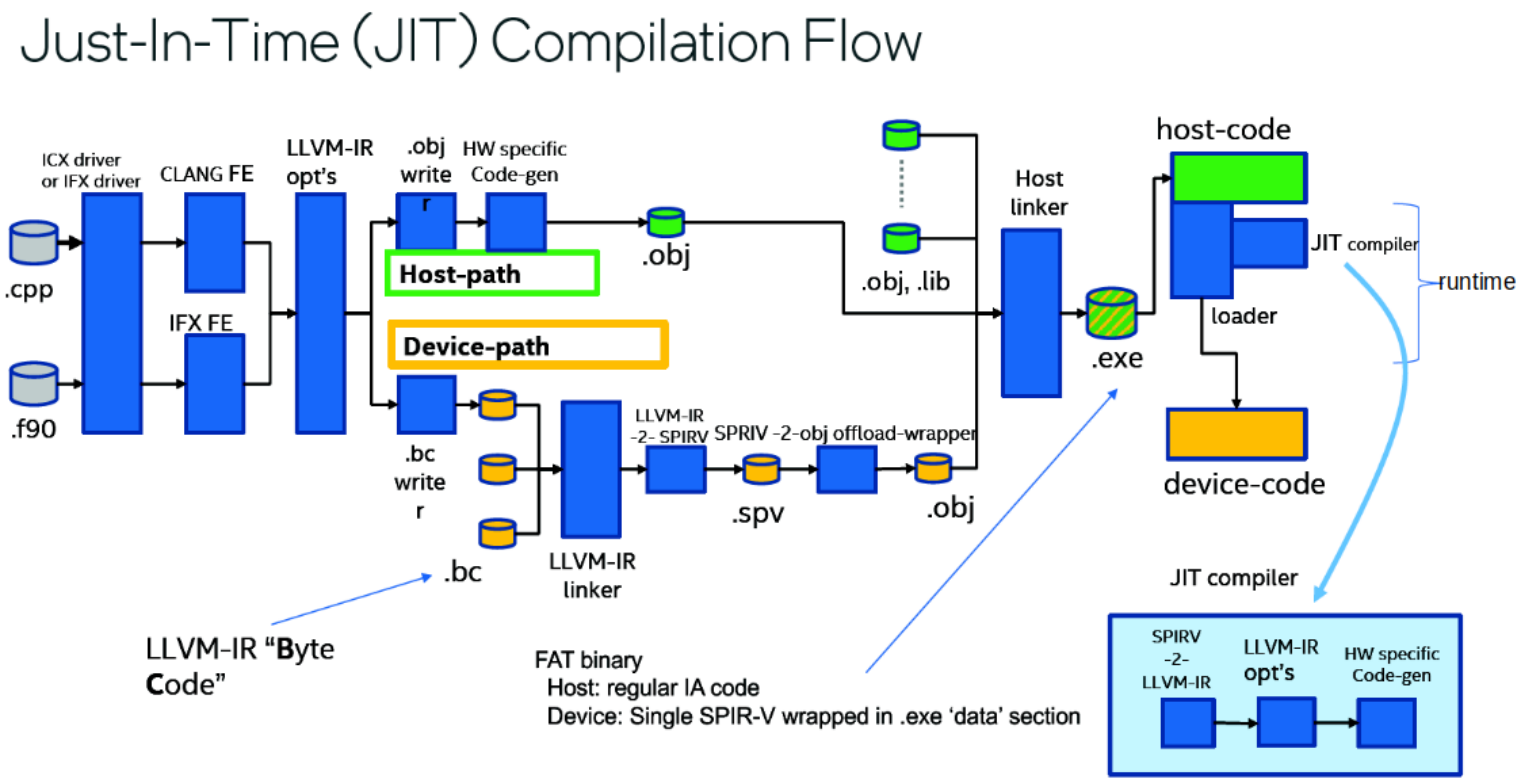

Ejemplo HelloWorld

- Opción de monitorizar uso del cómputo paralelo, haciendo uso de profiler del runtime de la librería *libomptarget*
- Para activar el profiler se puede hacer uso de la variable de entorno *LIBOMPTARGET_PLUGIN_PROFILE*

Terminal #1

```
user@system:~$ LIBOMPTARGET_PLUGIN_PROFILE=T ./simple

Running on GPU
...

================================================================================
LIBOMPTARGET_PLUGIN_PROFILE(OPENCL) for OMP DEVICE(0) Intel(R) UHD Graphics 620 [0x5917], Thread 0
--------------------------------------------------------------------------------
-- Kernel 0                  : __omp_offloading_10303_4e2ec6__Z4main_l21
--------------------------------------------------------------------------------
-- Name                      :     Host Time (msec)   Device Time (msec)
-- Compiling                 :                0.365                0.000
-- DataAlloc                 :                0.054                0.000
-- DataRead (Device to Host) :                0.153                0.006
-- DataWrite (Host to Device):                0.292                0.009
-- Kernel 0                  :                0.087                0.004
-- Linking                   :              846.631                0.000
-- OffloadEntriesInit        :                3.245                0.000
-- Total                     :              850.827                0.020
================================================================================
```

Ejemplo HelloWorld

- Compilación: generación de reporte para conocer las rutinas "offload" con la opción `-qopt-rpt`
  - Visualización de información generada por el compilador en fichero **simple.optrpt**

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 -qopt-report=1 simple.cpp -o simple
user@system:~$ more simple.optrptr
---- Begin Inlining Report ----
COMPILE FUNC: __omp_offloading_10303_4e2ec6__Z4main_l21

---- End Inlining Report ------
```

Ejemplo HelloWorld

- Compilación: generación de reporte para conocer las rutinas "offload" con la opción `-qopt-rpt`
  - Visualización de información generada por el compilador en fichero **simple-openmp-spir64.opt.yaml**
  - Comprobar **líneas 21 y 24**

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 -qopt-report=1 simple.cpp -o simple
user@system:~$ more simple-openmp-spir64.opt.yaml
...
--- !Missed
Pass:            openmp
Name:            Target
DebugLoc:        { File: simple.cpp, Line: 24, Column: 1 }
Function:        main
Args:
  - String:          Consider using OpenMP combined construct with "target" to get optimal perform
...
Pass:            openmp
Name:            Region
DebugLoc:        { File: simple.cpp, Line: 24, Column: 1 }
Function:        main
Args:
  - Construct:       parallel loop
  - String:          construct transformed
...
--- !Passed
Pass:            openmp
Name:            Region
DebugLoc:        { File: simple.cpp, Line: 21, Column: 1 }
Function:        __omp_offloading_10303_4e2ec6__Z4main_l21
Args:
  - Construct:       target
  - String:          construct transformed
...
```

Variables de entorno

- Selección de dispositivo con variable de entorno
  - `OMP_TARGET_OFFLOAD = mandatory | disabled | default`
    - mandatory: la región *target* ejecuta en GPU u otro acelerador
    - disabled: región *target* en CPU
    - default: región *target* en GPU (si hubiese), sino en CPU
- Selección de Plugin/Driver
  - `LIBOMPTARGET_PLUGIN= [OPENCL | LEVEL0 ]`
  - `LIBOMPTARGET_DEVICETYPE= gpu | cpu`
- Perfilado de ejecución en GPU
  - `LIBOMPTARGET_PLUGIN_PROFILE=T`
- Depuración
  - `LIBOMPTARGET_DEBUG= [1 | 2]`
  - Más información en el runtime del LLVM

Arquitectura Intel GPU

- En el caso de Intel, las GPUs son modulares agrupadas estructuras de Slice y Subslice
  - Ej: Intel Gen9 Slice=3 subslices, Gen11 Slice=8 subslices
    - 1 Subslice = 8 EUs
  - Cada subslice contiene un Unit-Dispacher y una Shared Local Memory (SLM) de 64KB
  - Cada EU tiene 2 ALUs SIMD-128bits:
    - 16xFP32 simultaneamente en cada EU: 2ALUs$SIMD\text{-}4$ 2 Ops (Add+Mul)

Arquitectura Intel GPU

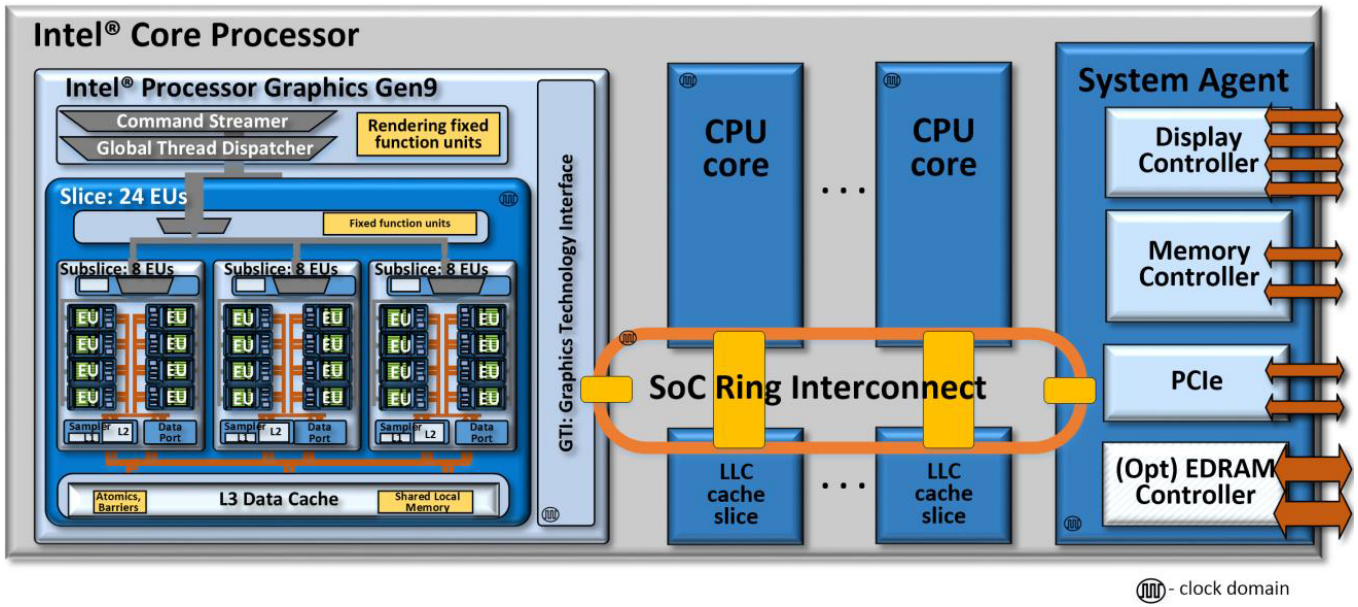

Best-Practices

- Algunos consejos y buenas prácticas para la programación y explotación de paralelismo heterogéneo
- Ejemplos:
  - Usando mejor los recursos de la GPU
  - Impacto de transferencia de datos
  - Variables escalares por copia
  - Reducir sincronizaciones
- Ejemplos extraidos de la web

Best-Practices

- Mejor uso de recursos en GPU
  - Paralelización bucle `for (b = 0; b < BLOCKS; b++)`

test_no_collapse.cpp

```
...
  /* offload the kernel with no collapse clause */
  #pragma omp target teams distribute parallel for \
    private(b, i, j, k, l)
  for (b = 0; b < BLOCKS; b++) {
    for (i = 0; i < P; i++) {
      for (j = 0; j < P; j++) {
        for (k = 0; k < P; k++) {
          double ur = 0.;
          double us = 0.;
          double ut = 0.;

          for (int t=0 ; t < TIMES; t++)
            for (l = 0; l < P; l++) {
              ur += dx[IDX2(i, l)] * u[IDX4(b, l, j, k)];
              us += dx[IDX2(k, l)] * u[IDX4(b, i, l, k)];
              ut += dx[IDX2(j, l)] * u[IDX4(b, i, j, l)];
            }

          w[IDX4(b, i, j, k)] = ur * us * ut;
        }
      }
    }
  }
...
```

Best-Practices

- Evaluación de ejecución con variable entorno `LIBOMPTARGET_DEBUG=1`
  - SIMD: 8
  - Número de teams: {4, 1, 1}
- Sin las clausula *collapse*, las iteraciones del bucle=4 porque *BLOCKS=4*

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 test_no_collapse.cpp
user@system:~$ OMP_TARGET_OFFLOAD=MANDATORY LIBOMPTARGET_DEBUG=1 ./a.out
...
Libomptarget --> Launching target execution __omp_offloading_10303_4e5bac__Z4main_l54 with pointer
...
Target OPENCL RTL --> Assumed kernel SIMD width is 8
Target OPENCL RTL --> Preferred group size is multiple of 8
Target OPENCL RTL --> Loop 0: lower bound = 0, upper bound = 3, Stride = 1
Target OPENCL RTL --> Team sizes = {1, 1, 1}
Target OPENCL RTL --> Number of teams = {4, 1, 1}
...
```

Best-Practices

- Clausula *collapse(2)*, las iteraciones del bucle=8 porque BLOCKS*P = 4*8 = 32
  - SIMD: 8
  - Team sizes:{4,1,1} y Número de teams: {2,4,1} luego **Número total teams: {8,4,1}=32**

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 test_collapse2.cpp
user@system:~$ OMP_TARGET_OFFLOAD=MANDATORY LIBOMPTARGET_DEBUG=1 ./a.out
...
Libomptarget --> Launching target execution __omp_offloading_10303_4e5bac__Z4main_154 with pointer
Libomptarget --> Manifesting used target pointers:
Target OPENCL RTL --> Assumed kernel SIMD width is 8
Target OPENCL RTL --> Preferred group size is multiple of 8
Target OPENCL RTL --> Loop 0: lower bound = 0, upper bound = 7, Stride = 1
Target OPENCL RTL --> Loop 1: lower bound = 0, upper bound = 3, Stride = 1
Target OPENCL RTL --> Team sizes = {4, 1, 1}
Target OPENCL RTL --> Number of teams = {2, 4, 1}
...
```

Best-Practices

- Clausula *collapse(3)*, las iteraciones del bucle=8 porque BLOCKS*P*P = 4*8*8 = 256
  - SIMD: 8
  - Team sizes:{8,1,1} y Número de teams: {1,8,4} luego **Número total teams: {8,8,4}=256**

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 test_collapse2.cpp
user@system:~$ OMP_TARGET_OFFLOAD=MANDATORY LIBOMPTARGET_DEBUG=1 ./a.out
...
Target OPENCL RTL --> Assumed kernel SIMD width is 8
Target OPENCL RTL --> Preferred group size is multiple of 8
Target OPENCL RTL --> Loop 0: lower bound = 0, upper bound = 7, Stride = 1
Target OPENCL RTL --> Loop 1: lower bound = 0, upper bound = 7, Stride = 1
Target OPENCL RTL --> Loop 2: lower bound = 0, upper bound = 3, Stride = 1
Target OPENCL RTL --> Team sizes = {8, 1, 1}
Target OPENCL RTL --> Number of teams = {1, 8, 4}
...
```

Best-Practices

- Clausula *collapse(4)*, las iteraciones del bucle=8 porque BLOCKS*P*P*P = 4*8*8*8 = 2048
  - SIMD: 8
  - Team sizes:{8,1,1} y Número de teams: {256,1,1} luego **Número total teams: {2048,1,1}=2048**

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 test_collapse2.cpp
user@system:~$ OMP_TARGET_OFFLOAD=MANDATORY LIBOMPTARGET_DEBUG=1 ./a.out
...
Libomptarget --> Launching target execution __omp_offloading_10303_4e5bac__Z4main_l54 with pointer
Libomptarget --> Manifesting used target pointers:
Target OPENCL RTL --> Assumed kernel SIMD width is 8
Target OPENCL RTL --> Preferred group size is multiple of 8
Target OPENCL RTL --> Loop 0: lower bound = 0, upper bound = 2047, Stride = 1
Target OPENCL RTL --> Team sizes = {8, 1, 1}
Target OPENCL RTL --> Number of teams = {256, 1, 1}
...
```

Best-Practices

- Resumen uso mejor de recursos de GPU:
  - time sin-collapse = 2.134297 s.
  - time collapse(2) = 0.271104 s.
  - time collapse(3) = 0.016485 s.
  - time collapse(4) = 0.010648 s.

Best-Practices

- Minimización de transferencias entre memorias CPU-GPU
  - Transferencias de datos entre el host y el dispositivo

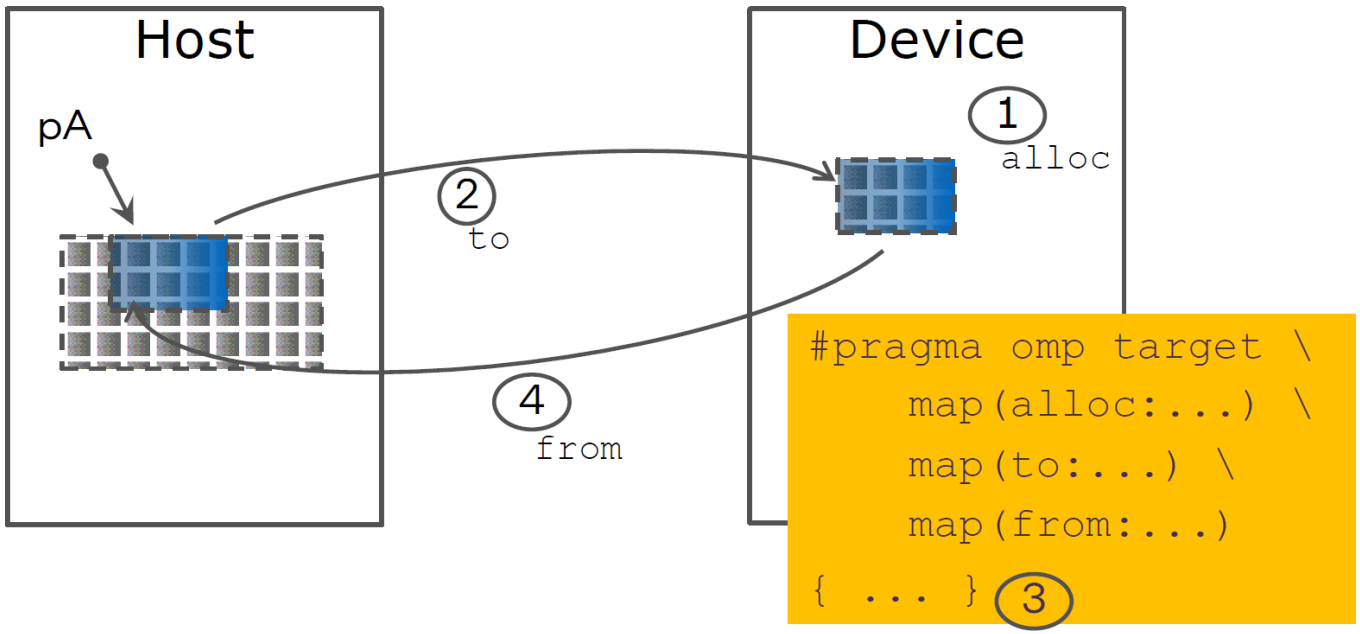

Best-Practices

- Ejecuciones de los kernel#1 y kernel#2 con sus operaciones de **transferencias de datos: map**

test_no_target_enter_exit_data.cpp

```
...
  /* offload kernel #1 */
  #pragma omp target teams distribute parallel for collapse(4) \
    map(to: u[0:SIZE], dx[0:P * P]) map(from: w[0:SIZE]) \
    private(b, i, j, k, l)
  for (b = 0; b < BLOCKS; b++) {
    for (i = 0; i < P; i++) {
      for (j = 0; j < P; j++) {
        for (k = 0; k < P; k++) {
            .....
        }
      }
    }
  }

  /* offload kernel #2 */
  #pragma omp target teams distribute parallel for collapse(4) \
    map(to: u[0:SIZE], dx[0:P * P]) map(tofrom: w[0:SIZE]) \
    private(b, i, j, k, l)
  for (b = 0; b < BLOCKS; b++) {
    for (i = 0; i < P; i++) {
      for (j = 0; j < P; j++) {
        for (k = 0; k < P; k++) {
           .....
        }
      }
    }
  }

...
```

Best-Practices

- Clausula *collapse(4)* para mejorar la "ocupación de GPU"
- Kernels generados para las líneas **47** y **71** con el particionado Team sizes:{16,1,1} y Número de teams: {128,1,1}

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 test_no_target_enter_exit_data.cpp
user@system:~$ OMP_TARGET_OFFLOAD=MANDATORY LIBOMPTARGET_DEBUG=1 ./a.out
...
Libomptarget --> Launching target execution __omp_offloading_10303_4e1c07__Z4main_l47 with pointer
Libomptarget --> Manifesting used target pointers:
Target OPENCL RTL --> Assumed kernel SIMD width is 16
Target OPENCL RTL --> Preferred group size is multiple of 16
Target OPENCL RTL --> Loop 0: lower bound = 0, upper bound = 2047, Stride = 1
Target OPENCL RTL --> Team sizes = {16, 1, 1}
Target OPENCL RTL --> Number of teams = {128, 1, 1}
...
Libomptarget --> Launching target execution __omp_offloading_10303_4e1c07__Z4main_l71 with pointer
Libomptarget --> Manifesting used target pointers:
Target OPENCL RTL --> Assumed kernel SIMD width is 16
Target OPENCL RTL --> Preferred group size is multiple of 16
Target OPENCL RTL --> Loop 0: lower bound = 0, upper bound = 2047, Stride = 1
Target OPENCL RTL --> Team sizes = {16, 1, 1}
Target OPENCL RTL --> Number of teams = {128, 1, 1}
...
```

Best-Practices

- ¿Pero y relativo a la cantidad de datos transferidos?
  - Filtrar la salida por "Libomptarget –> Moving"
- Recordando las transferencias para los kernels:
  - kernel#1: `map(to: u[0:SIZE], dx[0:P * P]) map(from: w[0:SIZE])`
    - double u[SIZE]=$8B * BLOCKS * P * P * P = 8 * 4 * 8 * 8 * 8 = 16384$
    - double dx[$P * P$]=$8 * 8 * 8 = 512$
    - double w[SIZE]=16384
  - kernel#2: `map(to: u[0:SIZE], dx[0:P * P]) map(tofrom: w[0:SIZE])`
    - double u[SIZE]=16384
    - double dx[$P * P$]=512
    - double w[SIZE]=16384

Best-Practices

- ¿Pero y relativo a la cantidad de datos transferidos?
  - kernel#1: `map(to: u[0:SIZE], dx[0:P * P]) map(from: w[0:SIZE])`
    - double u[SIZE]=16384, dx[P*P]=512, w[SIZE]=16384
  - kernel#2: `map(to: u[0:SIZE], dx[0:P * P]) map(tofrom: w[0:SIZE])`
    - double u[SIZE]=16384, dx[P*P]=512, w[SIZE]=16384
- Pero **¿hace falta en el kernel#2 enviar 'u', 'dx' y 'w'?**

Terminal #1

```
user@system:~$ OMP_TARGET_OFFLOAD=MANDATORY LIBOMPTARGET_DEBUG=1 ./a.out &> test_no_target_enter_e
user@system:~$ grep "Libomptarget --> Moving" test_no_target_enter_exit_data.debug
Libomptarget --> Moving 512 bytes (hst:0x00007ffcc6d972a0) -> (tgt:0xffffd556aa7e0000)
Libomptarget --> Moving 16384 bytes (hst:0x00007ffcc6d932a0) -> (tgt:0xffffd556aa7d0000)
Libomptarget --> Moving 16384 bytes (tgt:0xffffd556aa7c0000) -> (hst:0x00007ffcc6d8f2a0)
Libomptarget --> Moving 512 bytes (hst:0x00007ffcc6d972a0) -> (tgt:0xffffd556aa7e0000)
Libomptarget --> Moving 16384 bytes (hst:0x00007ffcc6d932a0) -> (tgt:0xffffd556aa7d0000)
Libomptarget --> Moving 16384 bytes (hst:0x00007ffcc6d8f2a0) -> (tgt:0xffffd556aa7c0000)
Libomptarget --> Moving 16384 bytes (tgt:0xffffd556aa7c0000) -> (hst:0x00007ffcc6d8f2a0)
```

Best-Practices

- Pero **¿hace falta en el kernel#2 enviar 'u', 'dx' y 'w'?**
- Usar `omp target enter data map` y `omp target exit data map`

test_target_enter_exit_data.cpp

```
...
  /* map data to device. alloc for w avoids map(tofrom: w[0:SIZE])
     on target by default. */
  #pragma omp target enter data map(to: u[0:SIZE], dx[0:P * P]) \
    map(alloc: w[0:SIZE])

  /* offload kernel #1 */
  ...

  /* offload kernel #2 */
  ...

  #pragma omp target exit data map(from: w[0:SIZE])
...
```

Terminal #1

```
user@system:~$ icpx -fiopenmp -fopenmp-targets=spir64 test_target_enter_exit_data.cpp
user@system:~$ OMP_TARGET_OFFLOAD=MANDATORY LIBOMPTARGET_DEBUG=1 ./a.out &> test_target_enter_exit
user@system:~$ grep "Libomptarget --> Moving" test_target_enter_exit_data.debug
Libomptarget --> Moving 16384 bytes (hst:0x00007ffdc04721b0) -> (tgt:0xffffd556aa7e0000)
Libomptarget --> Moving 512 bytes (hst:0x00007ffdc04761b0) -> (tgt:0xffffd556aa7d0000)
Libomptarget --> Moving 16384 bytes (tgt:0xffffd556aa7c0000) -> (hst:0x00007ffdc046e1b0)
```

Best-Practices

- Resumen uso eficiente de transferencias memorias CPU-GPU:
  - time sin enter/exit data: 0.002407 s.
  - time con enter/exit data: 0.001089 s.

Best-Practices

- Variables escalares por copia
  - Cuando hay variables escalares de entrada (**s1, s2, s3**) a un kernel que solamente se pasan por copia es preferible definirlas como `firstprivate` en lugar de enviarlas con `map`

test_scalars_map.cpp

```
...
 /* map data to device. alloc for w avoids map(tofrom: w[0:SIZE])
    on target by default. */
 #pragma omp target enter data map(to: u[0:SIZE], dx[0:P * P]) \
  map(alloc: w[0:SIZE])

 /* offload the kernel with collapse clause */
 #pragma omp target teams distribute parallel for collapse(4) \
  map(to: s1, s2, s3) private(b, i, j, k, l)
 for (b = 0; b < BLOCKS; b++) {
  for (i = 0; i < P; i++) {
   for (j = 0; j < P; j++) {
    for (k = 0; k < P; k++) {
     double ur = 0.;
     double us = 0.;
     double ut = 0.;

     for (l = 0; l < P; l++) {
      ur += dx[IDX2(i, l)] * u[IDX4(b, l, j, k)] + s1;
      us += dx[IDX2(k, l)] * u[IDX4(b, i, l, k)] - s2;
      ut += dx[IDX2(j, l)] * u[IDX4(b, i, j, l)] * s3;
     }

     w[IDX4(b, i, j, k)] = ur * us * ut;
    }
   }
  }

 ...

 #pragma omp target exit data map(from: w[0:SIZE])
...
```

Best-Practices

- Variables escalares por copia:
  - Tiempo del kernel: 0.001143 s. vs 0.000871 s.

Jacobi

- Método iterativo para resolución de ec. diferenciales
  - Ej: solución para la ecuación de Laplace 2D ($\nabla^2 f(x,y) = 0$)
- A tener en cuenta
  - Dos kernels dependientes
  - Transferencia de datos (minimizar transferencia de datos), **no en cada kernel**
  - Variable *error* del primer kernel debe de actualizarse host-device

$$A_{k+1}(i,j) = \frac{A_k(i-1,j)+A_k(i+1,j)+A_k(i,j-1)+A_k(i,j+1)}{4}$$

jacobi.c

```
while ( error > tol && iter < iter_max ){
       error = 0.0;

       for( int j = 1; j < n-1; j++){
          for( int i = 1; i < m-1; i++ ){
             Anew[j][i] = 0.25 * ( A[j][i+1] + A[j][i-1]
                                 + A[j-1][i] + A[j+1][i]);
             error = fmax( error, fabs(Anew[j][i] - A[j][i]));
          }
       }

       for( int j = 1; j < n-1; j++){
          for( int i = 1; i < m-1; i++ )
          {
             A[j][i] = Anew[j][i];
          }
       }

       if(iter % 100 == 0) printf("%5d, %0.6f\n", iter, error);

       iter++;
    }
}
```

Ecuación del calor

- La ecuación del calor (ec. difusión) es un problema comúnmente utilizado en los tutoriales de computación paralela
  - Consiste en la resolución de un sistema de ecuaciones aplicando el concepto de discretización
    - Los métodos de discretización más comunes son de primer grado de Euler
  - Utilizado en computación paralela por el número elevado de celdas que hay que "resolver" simultáneamente
  - Código extraido del Advanced Computing in Europe (PRACE)

Ecuación del calor

- **Resumiendo**: la ecuación del calor-2D se resuelve discretizando cada punto con stencil de 5

step_heat2D.c

```
for (unsigned int y = 1; y < N-1; ++y) {
     for (unsigned int x = 1; x < N-1; ++x) {
         next[y*N+x] = current[y*N+x] + a * dt *
             ((current[y*N+x+1] - 2.0*current[y*N+x] + current[y*N+x
                 -1])/dx2 +
              (current[(y+1)*N+x] - 2.0*current[y*N+x] + current[(y-1)*
                  N+x])/dy2);
     }
 }
```

Ecuación del calor (Heat2D)

- Tras 20000 iteraciones

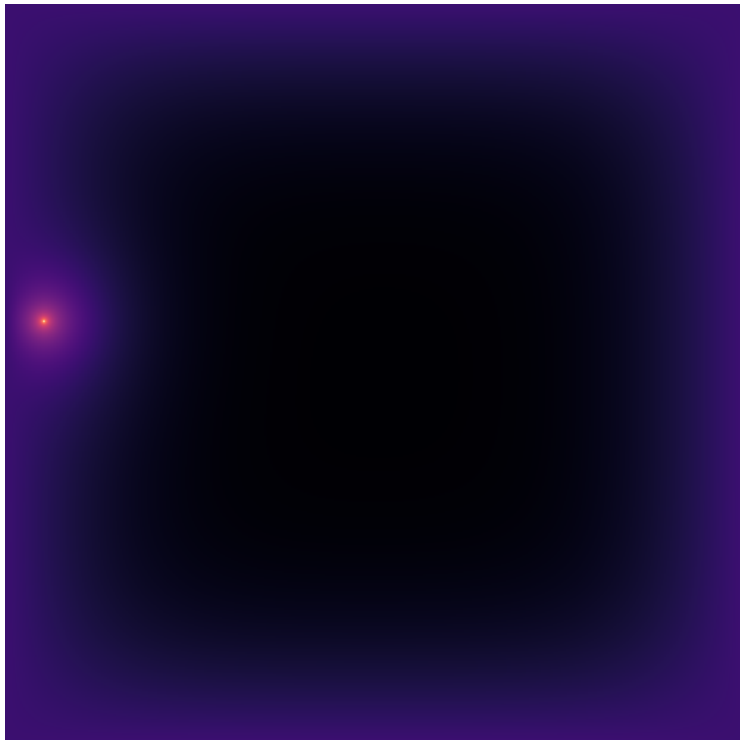

Heat2D

- Paralelizar el código **heat2d** con el paradigma OpenMP target
  - Prestar especial atención a la función *step* y *diff* que es la parte que más carga computacional soporta
  - Las funciones *step* y *diff* se invocan desde el main y en el bucle `for (unsigned int it = 0; ...`
    - Ambas funciones invocadas desde región **target** deben definirse como funciones o variables que son mapeadas en el dispositivo
    - Se recomienda consultar la directiva `#pragma omp declare target` para poderse llamar desde región "target"

Heat2D

- **A tener en cuenta**:
  1. Aunque la variable *current* debería estar definida con un `target map` de entrada/salida al dispositivo
  2. La variable *next* contiene datos inicializados del contorno (ver la invocación de `init(source_x, source_y, next);`) por lo que también debe debería de definida como **entrada**
  3. En la función *step* hay un kernel evidente: **stecil-5**

  - ... pero también se añade el foco de calor en la línea `next[source_y*N+source_x] = SOURCE_TEMP;`
  - Importante definir esta operación como otro kernel para que se pueda computar en el dispositivo porque sino se especifica como `#pragma omp target` no se ejecutará en el dispositivo

Heat2D

- **A tener en cuenta**:
  4. Variables definidas del tipo `static const` que quieran llevarse al acelerador deben de ir precedidas por `#pragma omp declare target`

Esteanografía

- Técnica para ocultar información o mensaje secreto
- Las técnicas más comunes son en documentos, imágenes...

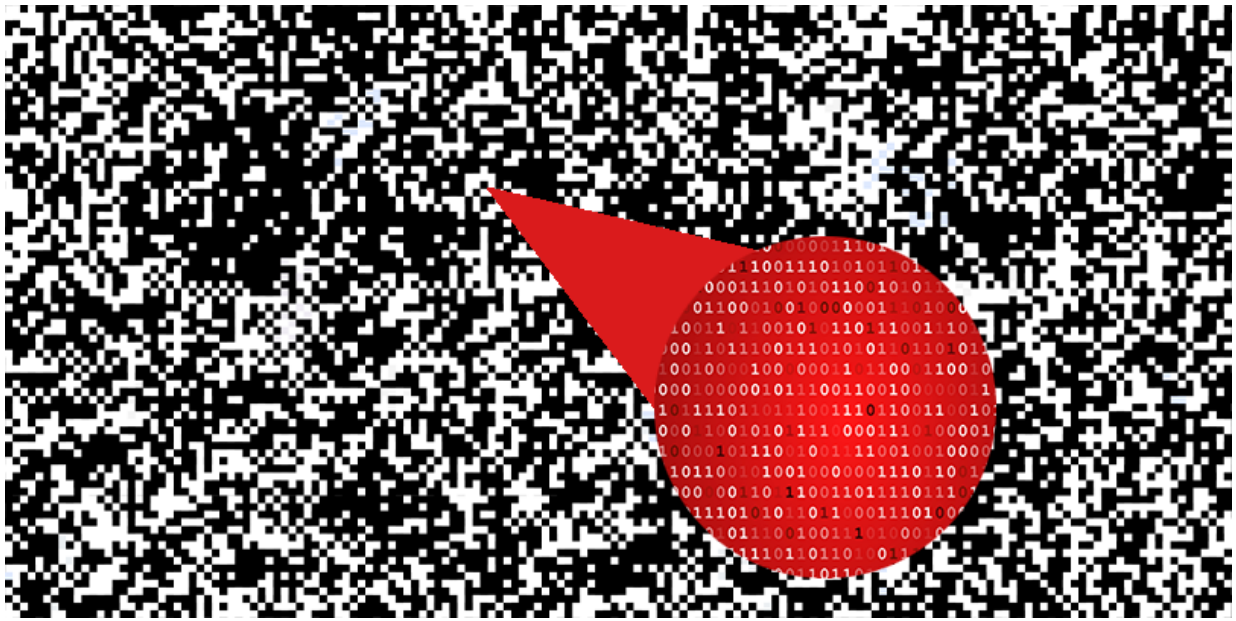

Esteanografia

- Código correspondiente al paper "Portable real-time DCT-based steganography using OpenCL"
  - Conversión RGB a YCrCb
  - Aplicación de transformada DCT8x8 al canal Y
  - Inserción de mensaje oculto
  - Transformación inversa iDCT8x8 del canal Y
  - Cambio Y'CrCb a RGB y almacenamiento de nueva imágen

Esteanografia

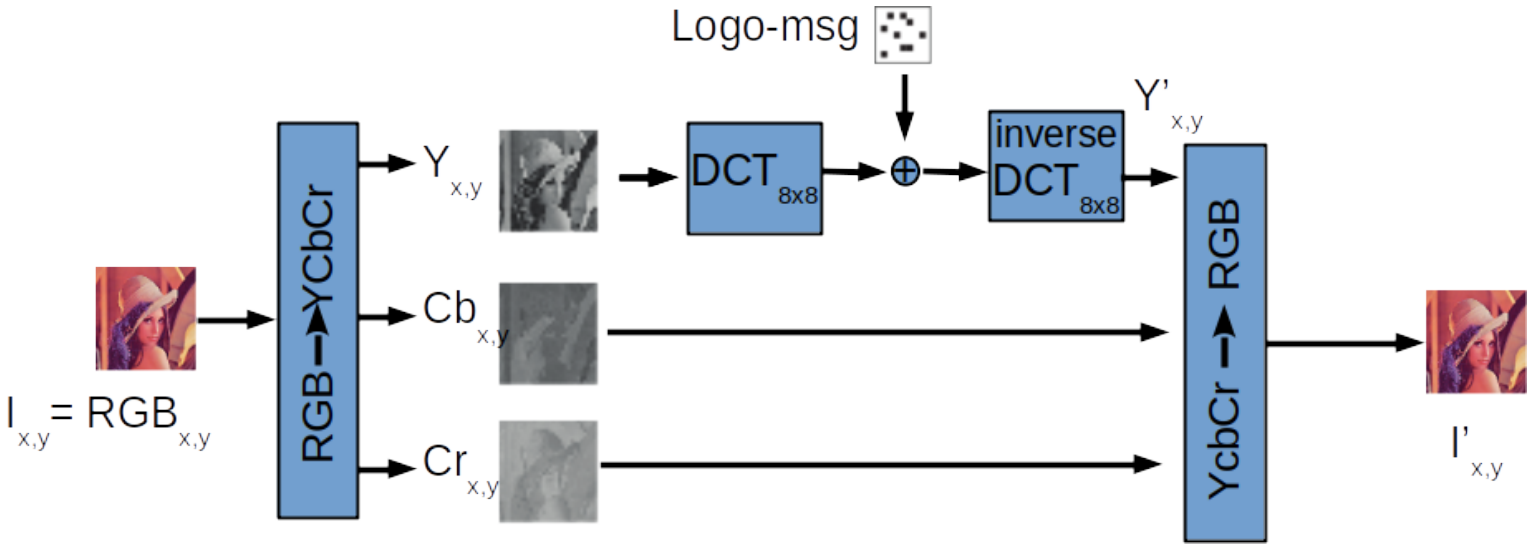

Esteanografia

- Paramétros de ejecución: “imagen_entrada.png logo.png image_salida.png”
  - Genera imágen de salida: “image_salida.png”
  - Mensaje recuperado: “logo_out.png”
- Dos funciones principales: `encoder` y `decoder`

main.c

```
int main(int argc, char **argv)
{
    ...
    // Encode the msg into image
    encoder(file_in, file_out, msg, msg_len);

    // Extract msg from image
    decoder(file_out, msg_decoded, msg_len);
    ...
}
```

Esteanografia

steano_routines.c

```
void encoder(...)
{
    ...
    get_dct8x8_params(mcosine, alpha);

    im2imRGB(im, w, h, &imRGB);
    rgb2ycbcr(&imRGB, &imYCrCb);
    dct8x8_2d(imYCrCb.Y, Ydct, imYCrCb.w, imYCrCb.h, mcosine, alpha);

    // Insert Message
    insert_msg(Ydct, imYCrCb.w, imYCrCb.h, msg, msg_len);

    idct8x8_2d(Ydct, imYCrCb.Y, imYCrCb.w, imYCrCb.h, mcosine, alpha);
    ycbcr2rgb(&imYCrCb, &imRGB);
    imRGB2im(&imRGB, im_out, &w, &h);

    ...
}
```

Intel Pefs Tool

- Herramientas usadas durante la asignatura
  - Intel Advisor
  - Intel VTune
- Para ello vamos a emplear una implementación del **Mandelbrot** disponible en github
  - 0: all test; 1: serial; 2: OpenMP SIMD; 3: OpenMP Parallel; 4: OpenMP Both
  - Nosotros añadiremos una nueva opción 5: **OpenMP offloading**

Intel Advisor

- Identificación de regiones potenciales a ser descargadas en GPU: Offload Modeling
- Analisis de Modelo Roofline para GPU: GPU Roofline

Advisor

- Intel Advisor permite proyectar descarga con el análisis **GPU Modeling**
- Dos alternativas:
  1. Proyección con el análisis `advisor-gui`
     - Modelo de GPU: **Target Platform Model**
  2. Por línea de comandos con `advisor`

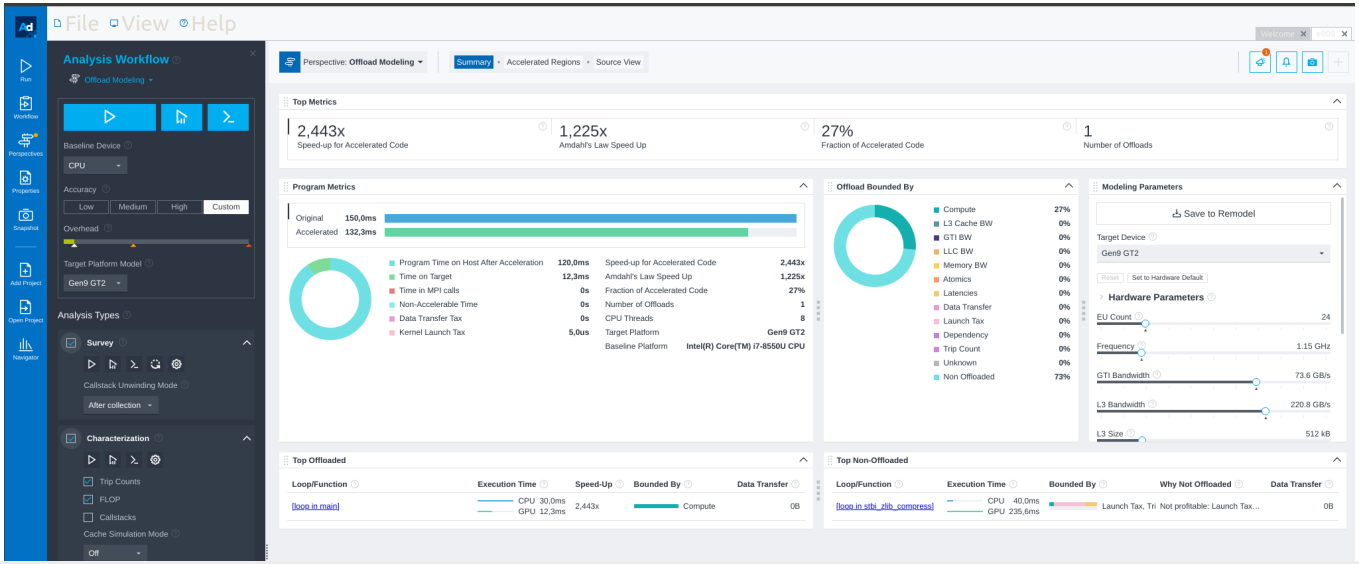

Advisor

- También es posible realizar el análisis por línea de comandos para posterior visualización

Terminal #1

```
user@system:~$ advisor --collect=survey --project-dir=./parallel_mandel --stackwalk-
mode=online --static-instruction-mix -- ./mandelbrot 3
user@system:~$ advisor --collect=tripcounts --project-dir=./parallel_mandel --flop --target-
device=gen9_gt2 -- ./mandelbrot 3
user@system:~$ advisor --collect=projection --project-dir=./parallel_mandel --config=gen9_gt2 --
no-assume-dependencies
...
Measured CPU Time: 0.150s    Accelerated CPU+GPU Time: 0.132s
Speedup for Accelerated Code: 2.4x    Number of Offloads: 1    Fraction of Accelerated Code: 27%

Top Offloaded Regions
-------------------------------------------------------------------------------------------
 Location                                              | CPU          | GPU          | Estimated
-------------------------------------------------------------------------------------------
 [loop in main]                                        |       0.030s |       0.012s |
-------------------------------------------------------------------------------------------
```

Mandelbrot offloading

1. Modificar el fichero **main.cpp** añadiendo una nueva opción que invoque la función *omp_mandelbrot_offloading* con la correspondiente salida png
2. Añadir dicha función a **mandelbrot.hpp**

main.cpp

```
int main(int argc, char* argv[]) {
...
  case 5: {
    printf("\nStarting OMP Mandelbrot offloading...\n");
    timer.start();
    output = omp_mandelbrot_offloading(x0, y0, x1, y1, width, height,
        max_depth);
    timer.stop();
    printf("Calculation finished. Processing time was %.0fms\n",
         timer.get_time() * 1000.0);
    printf("Saving image as mandelbrot_offload_parallel.png\n");
    write_image("mandelbrot_offload_parallel.png", width, height, output
        );
    _mm_free(output);
    break;
  }
...
}
```

Mandelbrot offloading

3. Añadir el código offloading en **mandelbrot.cpp** con la correspondiente `#pragma omp target`

mandelbrot.cpp

```
...
unsigned char* omp_mandelbrot_offloading(double x0, double y0, double x1
    ,
  double y1, int width, int height, int max_depth) {

  double xstep = (x1 - x0) / width;
  double ystep = (y1 - y0) / height;
  unsigned char* output = static_cast<unsigned char*>(
      _mm_malloc(width * height * sizeof(unsigned char), 64));


// Traverse the sample space in equally spaced steps with width * height
// samples
#pragma omp target teams distribute \
  parallel for simd collapse(2) \
  map(from:output[0:height*width]) map (to:height,width,xstep,ystep,
       max_depth)
  for (int j = 0; j < height; ++j) {
    for (int i = 0; i < width; ++i) {
      double z_real = x0 + i * xstep;
      double z_imaginary = y0 + j * ystep;
      double c_real = z_real;
      double c_imaginary = z_imaginary;

....

      output[j * width + i] = static_cast<unsigned char>(
          static_cast<double>(depth) / max_depth * 255);
    }
  }
  return output;
}
```

Advisor

- Vamos a comprobar la ganancia con el análisis **GPU Roofline Insights**
  - Recordar la opción 5 del mandelbrot para seleccionar el código offloading
  - EU Threading occupancy: **94.8 %** en mi sistema

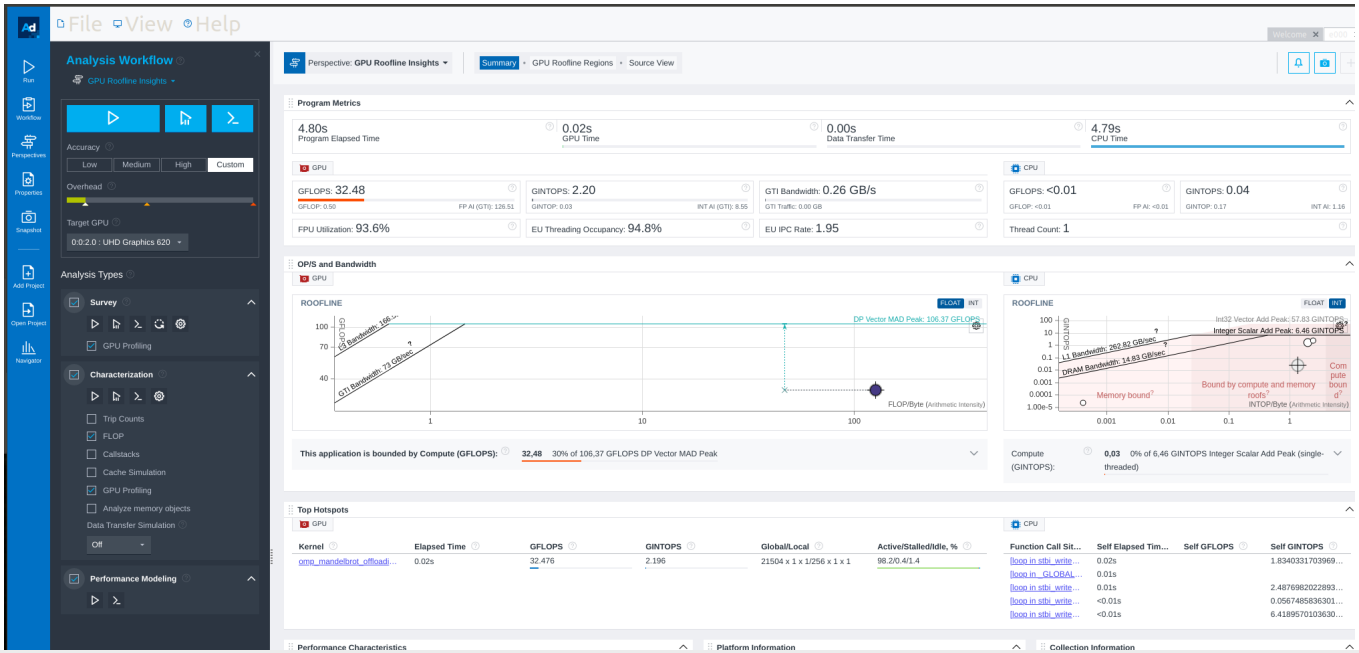

Advisor

- Se puede visualizar cada uno de los kernels: *omp_mandelbrot_offloading_:264*
  - **Compute bound**
  - Performance: 32.47Glops (float)
  - Bounded by DP Vector MAD Peak (Utilization: 30 %)

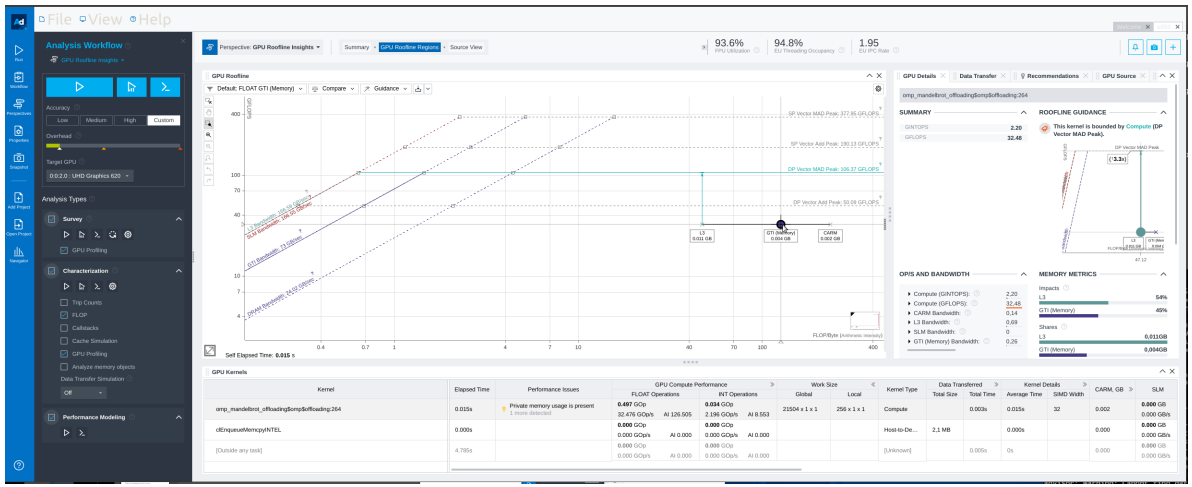

Advisor

- Vamos a comprobar la ganancia con el análisis **GPU Roofline Insights**
- ... pero por línea de comandos añadiendo la opción "–profile-gpu" seleccionando la opción 5(offloading)

Terminal #1

```
user@system:~$ advisor --collect=survey --flop --profile-gpu --project-
dir=./parallel_mandel -- ./mandelbrot 5

Program Elapsed Time: 4,16s

CPU Time: 4,14s

GPU Time: 0,02s
Data Transfer Time: < 0,01s
EU Array Active / Stalled / Idle: 99,3% / 0,5% / 0,1%

Top GPU Hotspots:
           Kernel                Time    Calls   Active   Stalled    Idle    EU Occupancy   Threa
-------------------------------------------------------------------------------------------------
omp_mandelbrot_offloading$o...   0.015s       1    99.3%      0.5%     0.1%          97.3%
```

Intel VTune

- Análisis **GPU Offload** determina el uso de la GPU
  - Más info en la guía de uso
- Métricas de ancho de banda con los diferentes niveles de la jerarquía de memoria
- Perfilado de hilo de ejecución
- Detalle del código y tiempo de ejecución de las tareas (CPU-GPU)

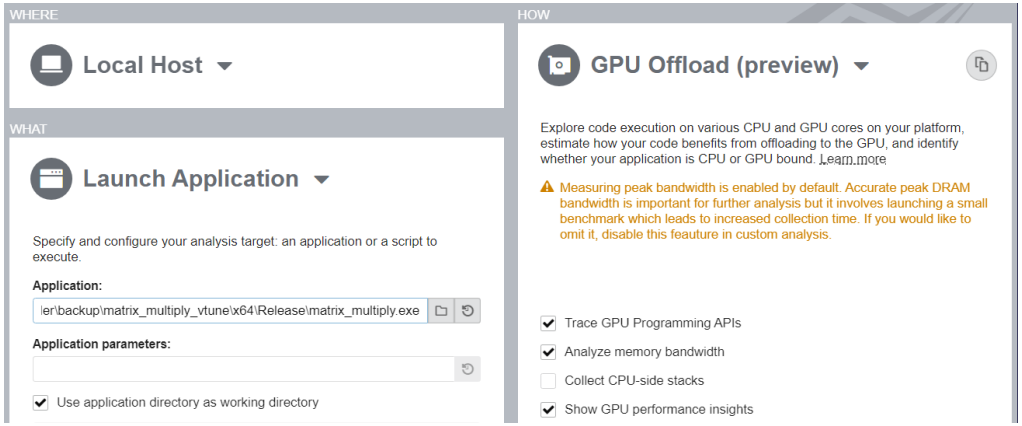

VTune (mandelbrot)

- Análisis **GPU Compute/Media Hotsposts**. Más info en la Guía VTune
  - Aunque la UE Array Stalled parece que es muy alto, es debido a la visualización y profiling simulténeo

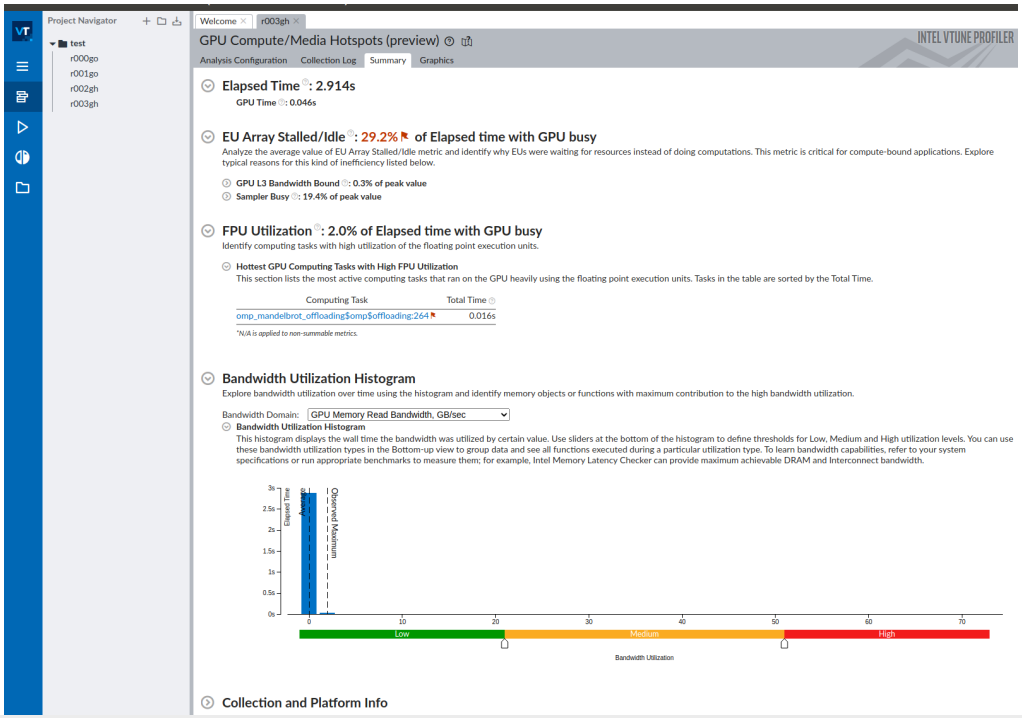

VTune (mandelbrot)

- En la solapa **“Graphics”** muestra un resumen de la ejecución
  - EU array: 98.2 % en consonancia con lo medido con el Advisor
  - Visualizción de aspectos como transferencia entre los niveles de memoria
    - Aunque no se observa ningún problema porque es *compute-bound*

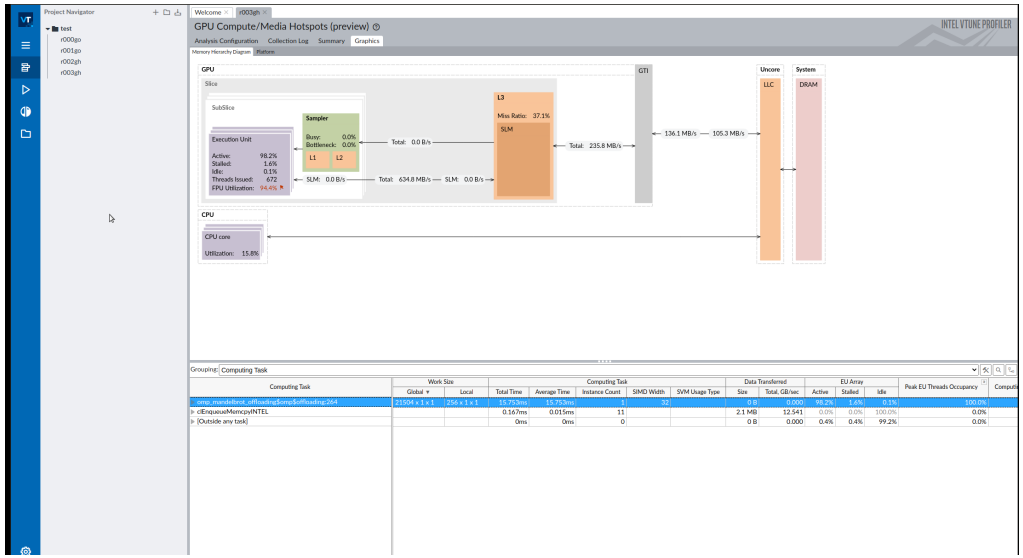

VTune (mandelbrot)

- Para un análisis más detallado de ejecución ir a solapa **“Platform”**
  - Muestra visión del uso de GPU y CPU
  - En nuestro ejemplo hay que hacer zoom para ver uso GPU